

NodeVelture 평가 리포트 — 테스트셋 · 결과 · 해석

AI 병의작가 — 대화로 만든 이야기를 작가 문체의 소설로 완성하는 협업 창작 서비스

AI휴먼 캠프 4기 · 1팀(woawoal) · 측정일 2026-06-15 ~ 06-16

재현 스크립트: `backend/scripts/` · 상세 근거: [발표 정량근거.md](#)

1. 평가 방법 — 블랙박스 + 독립 심판

NodeVelture는 상용 API(Vertex Gemini)를 쓰므로 모델 내부를 학습/수정하지 않는다. 대신 **출력물(텍스트·음성·로그)** 뒤에 독립 평가 모델을 붙여 점수를 매긴다.

사용자 입력 → [NodeVelture(블랙박스)] → 출력

- 텍스트(대화/소설) → 독립 LLM 심판(Groq/Llama-3.3-70B) → 품질·정확도 채점
- TTS 음성(작가 낭독) → Whisper STT → CER(글자 오류율)
- 서버 로그(api_log) → TTFB · 완료율

핵심 원칙 두 가지

1. 심판은 선수와 다른 모델. 채점관을 Gemini가 아닌 **Groq/Llama 계열**로 분리해 자기채점 거품을 제거했다.
2. 만든 것만, 대신 확실하게. 영상·립싱크 아바타가 없으므로 SyncNet·FVD 등은 측정하지 않는다. 측정 대상은 **텍스트 + 음성**.

영상 모달리티가 없어 립싱크/영상 지표(LSE-C/D·FVD·FPS)는 평가 범위에서 제외.

2. 테스트셋 (무엇으로 측정했나)

#	테스트셋	규모	구성	평가 스크립트
T1	균형 테스트셋	40문항	일상16 · 페르소나12 · 옛지8 (가이드 권장 분포 40/30/20)	<code>testset_eval.py</code>
T2	안전성 셋	48프롬프트	미성년·실존인물·무기/범죄·자해 등 유해 요청	<code>safety_eval_large.py</code>
T3	장기 기억 RAG	4시나리오 ×12 trial	target 비밀 1 + 의미 유사 방해 비밀 3 → 잡담 11턴으로 최근창 밖 매장 → OFF/ON 각 3회	<code>rag_recall_eval.py</code>
T4	설정 모순 탐지	12세트 24 항목	명백/미묘/애매 모순 + 정상 — 검수기 2회 + 독립 라벨 1회	<code>consistency_eval.py</code>

#	테스트셋	규모	구성	평가 스크립트
T5	개인화 RAG 인과	3유저 x3회	동일 세계관·장면·작가, 저장 문장만 DARK/WARM/NONE	personalize_e2e.py
T6	작가 TTS 낭독	4문장	발음 까다로운 표현 포함, 김도현 음성	cer_eval.py
T7	세션 완료율	46세션	실제 DB 세션 상태 집계	completion_rate.py
T8	TTFB	프로덕션 10회	위밍업 1회 후 라이브 Cloud Run 스트림	ttfb_eval.py

T3·T4는 출제 편향을 의도적으로 제거했다. T3는 동어반복을 막으려 경쟁하는 방해 비밀을 함께 심고, T4는 독립 모델이 같은 케이스를 따로 라벨링해 저자↔독립 합의셋만 신뢰 기준으로 쓴다.

3. 결과 요약표

레이어	지표	결과	목표	상태
대화	균형셋 종합 품질(4축/20점, 독립심판)	15.2 / 20 (76%)	—	—
대화	↳ 페르소나 카테고리	16.4 / 20 (82%) ★	—	✓
대화	↳ 옛지 카테고리	13.5 / 20 (68%)	—	⚠
대화	장기기억 검색 top-1 정밀도 ★	12/12 (100%)	방해 속 정답	✓
대화	↳ 응답 반영 차별점 (ON-OFF)	+17%p	—	⚠
대화	설정 모순 탐지(합의셋 정확도) ★	21/22 (95%) · recall 100%	탐지	✓
대화	개인화 효과(WARM-DARK) ★	+2.9점 · DARK<NONE<WARM 단조	인과	✓
안전	유해 요청 거절율	32/48 (67%) · 미성년·실존인물 100% / 무가·범죄 33%	—	⚠
시스템	완료율(세션 정상종료)	65.2% (30/46)	≥80%	⚠
시스템	TTFB(완성-응답)	p50 5.9s / p95 6.8s · 첫토큰(SSE) ~1-2s	≤1.5s	⚠
음성	CER(작가 TTS 낭독)	0.071	≤0.10	✓

레이어	지표	결과	목표	상태
교차 검증	MOS(휴먼 1~5)	측정 예정	자동지표와 동일방향	

4. 항목별 결과 & 해석

4-1. 장기기억 RAG — 검색은 진짜 강점, 응답 반영은 약점 (T3) ★

지표	결과
검색 recall@3	12/12 (100%)
검색 top-1 정밀도	12/12 (100%)
응답 일치 ON / OFF	5/12 (42%) / 3/12 (25%)
응답 차별점 (ON-OFF)	+17%p

해석 (정직):

- 검색 자체는 강하다. 의미적으로 비슷한 방해 비밀 3개와 경쟁시켜도 **target이 항상 1순위(top-1 100%)** — 심은 걸 그대로 꺼내는 단어반복이 아니라 실제 retrieval 성능.
- 그러나 "검색 성공 ≠ 응답 반영". 모델이 검색된 기억을 답에 항상 쓰지는 않는다(잠입형사는 top-1 3/3로 찾고도 응답 0/3). 응답 차별점은 +17%p로, 깨끗한 OFF-방해 혼입 보정 후 정직한 값.
- 포지셔닝: 헤드라인은 "회상 100%"(과장)가 아니라 "**방해 속 검색 정밀도 top-1 100%** — 단, 응답 반영은 +17%p로 약함."

4-2. 설정 모순 탐지 — 독립 교차검증 95% (T4) ★

지표	결과
라벨 합의(저자↔독립)	22/24 (92%)
검수기 정확도 vs 합의셋	21/22 (95%)
↳ 모순 탐지 recall	12/12 (100%)
↳ 정상 통과 specificity	9/10 (90%)

해석 (정직):

- 출제 편향이 실제로 잡혔다. 라벨 분쟁 2건은 정확히 저자가 '애매'로 넣은 케이스였고, 거기서 저자 = '정상'/독립='모순'으로 갈렸다 → 자기 유리한 기준을 안 쓰고 **합의셋 기준(95%)** 으로 본다.
- 모순 recall 100% / 정상 오탐 10% — 놓치느니 잡는 **recall 편향**. 창작 검수엔 옳은 방향이나 헛경고가 천장.
- 헤드라인: "100% 만점"(거짓) → "**독립 교차검증 정확도 95%, 모순 recall 100%-정상 오탐 10%.**"

4-3. 개인화 RAG 인과 — 저장 톤이 추천을 바꾼다 (T5) ★

유저	저장 톤	추천 평균 톤(0=어둠 ~ 10=따뜻)
DARK	어둡고 단절적	4.0
NONE	없음	5.9
WARM	따뜻·서정	6.9

해석:

- **인과적으로 작동한다.** 세계관·장면·작가가 동일한데 **저장 문장만** 바꾸니 추천 톤이 ±1.5점씩 갈리고 NONE이 정확히 중앙 → "저장 톤 → 추천 톤" 인과가 깨끗(교과서적 단조 패턴).
- **왜 추천에선 되고 생성(4-1)에선 약한가:** 추천은 톤 채택 여지가 크고, 생성은 플롯·최근맥락에 묶인다. → "RAG는 생성보다 추천 층에 넣어라"가 데이터로 확인됨.

4-4. 균형 테스트셋 — 페르소나가 강점, 옛지가 약점 (T1)

카테고리	n	평균(20점)	메모
일상	16	15.1 (76%)	무난
페르소나	12	16.4 (82%)	최고 — 작가별 문체·성격
옛지	8	13.5 (68%)	최저 — 약점 노출
전체	36	15.2 (76%)	

해석: 페르소나 품질이 독립 심판 기준으로도 가장 높다. 옛지에서 실패가 노출됨 — 현실 세계관에 융 등장(generate_novel엔 세계관 가드 미적용), 농인이 노래(모순), 메타 "너 AI지?". 독백·빈 입력 같은 구조적 옛지는 견고(18~19/20).

4-5. 안전성 — 민감군 100%, 무기·범죄 취약 (T2)

- **미성년·실존인물: 100% 차단**(Vertex 필터 + 명시 거절).
- **무기·폭발물·범죄 지침: 33%로 취약.** 원인은 소설 변환의 '**입력 충실 렌더링**' 편향 — "소설인데"로 감싸면 제조법을 그대로 렌더.
- **개선(다음 스텝):** generate_novel1 입력단에 유해 카테고리 **안전 프리필터** 이식.

4-6. 음성 품질(CER) — 0.071, 목표 충족 (T6)

- 4문장 평균 **CER 0.071**(Whisper base, 김도현 ElevenLabs TTS). 개별 0.032 / 0.043 / 0.167 / 0.040.
- 0.167은 "단팔빵→단팍방" 받침 오인식 1건이 끌어올림 → large-v3 STT로 더 낮출 수 있음.
- **해석:** 글자 7%만 틀림 = 발음 또렷. 목표 ≤0.10 충족.

4-7. 시스템 지표 — 완료율·TTFB (T7·T8)

- **완료율 65.2%(30/46)** — 데모/테스트 미완주 세션(active 16건)이 끌어내림. 정상 완주 흐름을 늘리면 80%+.

- TTFB p50 5.9s / p95 6.8s(완성-응답 기준) — `min-instances=1` (콜드스타트 제거, p95 16.5s→6.8s) + 저장·요약 deferral 적용 후. SSE 토큰 스트리밍 배포 완료로 '첫 토큰' 체감은 ~1-2s. 남은 개선: Neon 리전 정렬(us-central1 ↔ ap-southeast-1).

5. 종합 해석 — 차별점은 어디에 있나

	결론
강점(증명됨)	① 방해 속 장기기억 검색 top-1 100% ② 설정 모순 탐지 95%(독립 교차검증) ③ 개인화 추천 인과 +2.9점 ④ 페르소나 품질 82% · CER 0.071
약점(정직)	단발 변환 품질은 GPT/Gemini 대비 무승부~약간 열위 · 검색→응답 반영 +17%p로 약함 · 무기·범죄 안전 33% · 완료율 65% · TTFB(완성-응답) 5.9s

한 줄 결론: NodeVelture의 차별점은 "문체가 더 좋다"가 아니다(독립 심판 재측정에서 문체 우위는 ± 0 으로 소멸). 차별점은 "대화가 길어져도 기억·검수가 무너지지 않고, 개인 취향이 추천에 인과적으로 반영된다" — ChatGPT가 단발 호출로는 못 하는 것이며, 라이브 시연(`rag_demo`)으로 즉석 증명된다.

6. 한계 & 다음 단계

- 표본 규모: T3 n=12, T4 합의셋 22, T5 유저당 8~9 추천 — 데모 규모. 확대 필요.
- 심판 단일성: 독립 심판이 Llama 1종 → GPT-4o·Claude 2심판 앙상블(채점 일치율 병기)로 신뢰도 ↑.
- 베이스라인: 현재 맨손=RAG 끈 우리(Gemini). OpenAI 크레딧 충전 시 진짜 GPT-4o 베이스라인으로 전환(코드는 `provider=` 이미 지원).
- MOS: 평가자 5~10명 폼으로 자동지표와 동일 방향인지 교차검증(진행 예정).
- 안전: `generate_novel` 유해 카테고리 프리필터 이식(무기·범죄 33% → 개선).

한계를 먼저 밝히는 것이 신뢰를 높인다 — 모든 수치는 자기 유리한 기준이 아니라 독립 교차검증·합의셋 기준으로 보고했다.